データサイエンス 第一回講義課題

履修者アンケートの定量的分析 By 鈴木真理

履修者アンケートの定量分析 By Gemini

慶應義塾大学 総合政策学部　学籍番号: 72603857　鈴木 真理

2026 年 4 月 11 日

概要

本レポートでは，2026 年度春学期データサイエンス講義の履修者 912 名のスキルアンケートを定量的に分析した．核心は 3 点に集約される：**(1)** Python・SQL・R 間に有意な正の相関，特に Python×SQL が最強（$r = 0.450$, $p < 0.0001$）; **(2)** 学部間差は Python・他 PG のみ限定的に有意 ; **(3)** 性別間では PG 系で男性が有意に高く，Gender Neutrality 仮説は棄却.

1　はじめに

データサイエンス教育の効果的設計には，履修者の事前スキル分布の把握が不可欠である．本レポートでは，慶應義塾大学 SFC の 2026 年度春学期データサイエンス講義・第 1 回アンケート（$N = 912$; 環境情報 508, 総合政策 385, 他 19; 男 629, 女 279）を対象に 3 つの仮説を検証する：**H1.** Python・R・SQL 間に正の相関あり．**H2.** 学部間にスキル差あり．**H3.** 性別による偏りなし（Gender Neutrality）．全カラムで欠損 0 件，表記揺れ（計 28 件）を対処済み.

1.1　基本統計量（Descriptive Statistics）

表 1: スキル別基本統計量

スキル	Mean	SD	Med.
Excel 分析	2.16	0.80	2
Pivot Table	1.54	0.73	1
SQL	1.34	0.68	1
R	1.58	0.73	1
Python	**2.22**	**0.77**	**2**
他 PG	1.75	0.89	2

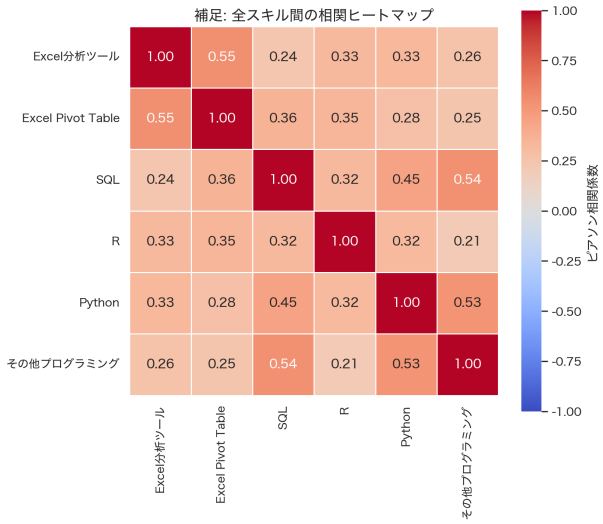

図 1: 全スキル相関行列

Python が最高の平均値（$\bar{x} = 2.22$）を示す一方，SQL・R・Pivot は中央値 1（未経験）．典型的な学生像は**「Python 初心者〜中級者，他ツールは未経験」**と特徴づけられる．図 1 に示す相関行列から，「Excel 系」と「PG 系（Python/SQL/他）」の **2 独立クラスター**が確認された.

2 仮説検証（Hypothesis Testing）

2.1 手法選択の根拠（Methodology）

スキルデータは 5 段階順序尺度であり正規分布の仮定が困難なため，2 群比較にはノンパラメトリックな Mann–Whitney U 検定 [2] を採用（正規性・等分散性不要，各群 $n > 279$）．相関には Pearson の積率相関係数 [1] を用いた．順序尺度への Pearson r 適用は，サンプルサイズが十分大きい場合に頑健な推定値を与えることが知られている．有意水準 $\alpha = 0.05$，$^{*}p < .05$, $^{**}p < .01$, $^{***}p < .001$ 表記．

2.2 H1: Python・R・SQL 間の相関 — 支持

表 2: H1: ペアワイズ相関（Pearson r）

ペア	r	p	
Python×R	0.320	<0.0001	∗∗∗
Python×SQL	**0.450**	**<0.0001**	∗∗∗
R×SQL	0.324	<0.0001	∗∗∗

3 ペアすべてで有意な正の相関．**Python×SQL** が最強（$r = 0.450$），「PG を学ぶ学生は DB も並行して学ぶ」SFC カリキュラムの連動を反映する．補足として，全スキル行列（図 1）では SQL× 他 PG（$r = 0.54$），Excel 分析 ×Pivot（$r = 0.55$）が各クラスターの中心をなす．

2.3 H2: 学部間スキル差 — 部分的支持

表 3: H2: 学部間比較（Mann–Whitney U）

	環情	総政	U	p	
Excel 分析	2.15	2.16	97,554	.947	n.s.
Pivot	1.52	1.57	93,956	.253	n.s.
SQL	1.36	1.32	98,430	.824	n.s.
R	1.56	1.59	95,446	.490	n.s.
Python	**2.27**	**2.17**	**104,940**	**.038**	∗
他 PG	**1.84**	**1.66**	**106,834**	**.010**	∗

Excel 系・SQL・R では有意差なし．Python（$p = .038$）・他 PG（$p = .010$）のみ環情が高いが，平均差 0.1–0.18pts. と**効果は限定的**．「技術系学部が全面優位」は棄却された．

2.4 H3: 性別スキル差 — PG 系で棄却

表 4: H3: 性別間比較（Mann–Whitney U）

	男	女	U	p	
Excel 分析	2.15	2.18	86,109	.627	n.s.
Pivot	1.54	1.52	88,608	.788	n.s.
SQL	**1.37**	**1.24**	**95,364**	**.005**	∗∗
R	1.59	1.52	92,266	.163	n.s.
Python	**2.27**	**2.09**	**98,167**	**.002**	∗∗
他 PG	**1.84**	**1.55**	**101,598**	**<.0001**	∗∗∗

Gender Neutrality 仮説は **PG 系で棄却**：SQL（$p = .005$），Python（$p = .002$），他 PG（$p < .0001$）で男性が有意に高い．Excel 系・R では差なし．これは PG への事前接触機会差を反映しており，導入期の支援強化の根拠となる．

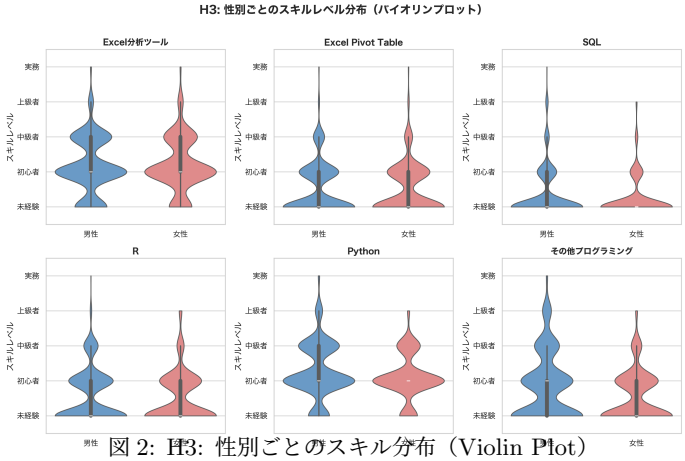

図 2: H3: 性別ごとのスキル分布（Violin Plot）

3 Pure NumPy による相関係数の実装

ライブラリ依存ではない数学的理解の証明として，ピアソン相関係数を NumPy の基本演算のみで実装する [3].

3.1 数学的背景 — Covariance と Standard Deviation

共分散（Covariance）$\mathrm{Cov}(X,Y)=\frac{1}{n}\sum(x_i-\bar{x})(y_i-\bar{y})$ と，標準偏差（Standard Deviation）$\sigma_X=\sqrt{\frac{1}{n}\sum(x_i-\bar{x})^2}$ に対し，ピアソン相関係数は共分散を両変数の標準偏差積で正規化（Normalization）した指標である：

$$\rho_{X,Y}=\frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y}=\frac{\displaystyle\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\displaystyle\sum_{i=1}^{n}(x_i-\bar{x})^2\cdot\sum_{i=1}^{n}(y_i-\bar{y})^2}} \tag{1}$$

$\bar{x},\bar{y}$ は標本平均（Sample Mean）．計算は 3 段階に分解：**(1)** 平均偏差 $d_{x_i}=x_i-\bar{x}$ （Mean Deviation），**(2)** 共分散分子 $\sum d_{x_i}d_{y_i}$ （Covariance Numerator），**(3)** L^2 ノルム正規化 $\rho=\mathrm{Cov}/\big(\|\boldsymbol{d}_x\|_2\cdot\|\boldsymbol{d}_y\|_2\big)$.

3.2 実装コード

```python
import numpy as np

def pearson_correlation(x: np.ndarray, y: np.ndarray) -> float:
    """Compute Pearson correlation coefficient using only NumPy primitives."""
    if len(x) != len(y):
        raise ValueError("Arrays must have equal length.")
    if len(x) < 2:
        raise ValueError("Need at least 2 data points.")

    # Step 1: Mean deviations  d_xi = xi - x_bar
    dx = x - np.mean(x)
    dy = y - np.mean(y)

    # Step 2: Covariance numerator = sum(dx * dy)
    numerator = np.sum(dx * dy)

    # Step 3: L2-norm normalization
    denominator = np.sqrt(np.sum(dx**2)) * np.sqrt(np.sum(dy**2))

    if denominator == 0.0:
        return 0.0  # Undefined (constant array)
    return float(numerator / denominator)
```

Listing 1: Pure NumPy によるピアソン相関係数

要点：`np.mean`, `np.sum`, `np.sqrt` のみ使用し，`np.corrcoef`/`scipy.stats.pearsonr` への依存を排除．式 (1) の分子・分母を直接計算し，数式 ↔ 実装の 1:1 対応が検証可能.

4 総合考察・提言と結論

Actionable Insights：**(1)** Python 一強（$\bar{x}=2.22/5$），基礎復習は短縮可能．**(2)** SQL・R・Pivot は中央値 1（未経験），ゼロからの導入が不可欠．**(3)** 「Excel 系」と「PG 系」の 2 独立クラスターが存在（図 1）．**(4)** 学部差は限定的（H2），学部混合で問題なし．**(5)** 性別差は要配慮（H3），事前経験差であり能力差ではない．学部・性別混合ペア PG ＋初学者スキャフォールディングを推奨.

おわりに：912 名のアンケートから 3 仮説を検証し定量的講義設計提言を行った．Python×SQL の相関（$r=0.450$）は SFC の PG 教育の相乗効果を示唆する．今後は期末アンケートとの前後比較，クラスタリングによるセグメンテーション，成績予測力の評価を進める.

参考文献

[1] K. Pearson. Notes on Regression and Inheritance in the Case of Two Parents. *Proc. R. Soc. Lond.*, 58:240–242, 1895.

[2] H. B. Mann and D. R. Whitney. On a Test of Whether one of Two Random Variables is Stochastically Larger than the Other. *Ann. Math. Statist.*, 18(1):50–60, 1947.

[3] C. R. Harris et al. Array programming with NumPy. *Nature*, 585(7825):357–362, 2020.