論文タイトルをここに入力

サブタイトル（任意）

キーワード: 深層学習, 最適化, 自然言語処理 By 鈴木真理

慶應義塾大学 総合政策学部　学籍番号: 72603857　鈴木 真理

2026 年 4 月 12 日

概要

本テンプレートは，LaTeX で使用頻度の高い学術的要素——数式・図・表・リスト・ソースコード・参考文献——に加え，TikZ・Algorithm2e・Tcolorbox・Cleveref・Glossaries の「五つの秘宝」を統合した決定版ボイラープレートである．コンパイルするだけで各要素の組版結果を網羅的に確認でき，コピー&ペーストで新しい論文へ即座に転用できるよう設計した．

1　数式のサンプル（amsmath パッケージ）

1.1　ガウス積分

ガウス積分は確率論・統計学・物理学の基礎をなす重要な積分公式である [1].

$$\int_{-\infty}^{\infty} e^{-x^2}\,dx = \sqrt{\pi} \tag{1}$$

式 (1) は正規分布の正規化定数の導出に直接的に用いられる．

1.2　勾配降下法の更新則

Machine Learning (ML) における最も基本的な最適化アルゴリズムである Stochastic Gradient Descent (SGD) は，パラメータ $\boldsymbol{\theta}$ を以下のように逐次更新する [2]：

$$\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} - \eta\,\nabla_{\boldsymbol{\theta}}\mathcal{L}\Big(\boldsymbol{\theta}^{(t)}\Big) \tag{2}$$

ここで $\eta > 0$ は学習率，$\mathcal{L}$ は損失関数である．式 (2) は Stochastic Gradient Descent (SGD) の基本形である．

1.3　ベイズの定理（aligned 環境）

$$\begin{aligned} P(A \mid B) &= \frac{P(B \mid A)\,P(A)}{P(B)} \\ &= \frac{P(B \mid A)\,P(A)}{\displaystyle\sum_i P(B \mid A_i)\,P(A_i)} \end{aligned} \tag{3}$$

1.4　行列表記

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b} \quad \Longleftrightarrow \quad \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{pmatrix} \tag{4}$$

2　図（Figure）の配置テンプレート

2.1　2 枚並び（minipage）

図 1: 左側の図のキャプション

図 2: 右側の図のキャプション

図 1 と図 2 はそれぞれ独立したキャプションとラベルを持つ．

2.2　3 枚並び（minipage）

図 3: 図 A

図 4: 図 B

図 5: 図 C

3　表（Table）のテンプレート — booktabs

3.1　基本的な学術誌水準の表

表 1: 各手法の性能比較（精度・再現率・F1 スコア）

手法	Precision	Recall	F1
ロジスティック回帰	0.82	0.79	0.80
ランダムフォレスト	0.88	0.85	0.86
勾配ブースティング	0.91	0.89	0.90
提案手法	**0.94**	**0.92**	**0.93**

表 1 に示すように，提案手法が全指標で他手法を上回っている．

3.2　tabularx を用いた可変幅テーブル

表 2: 分析手法の特徴比較

観点	従来手法	提案手法
計算量	$O(n^3)$ で大規模データに不向き	$O(n \log n)$ に改善
解釈性	ブラックボックス型	SHAP 値により局所的説明が可能
汎化性能	過学習しやすい	正則化により安定

4　リストのサンプル（enumitem パッケージ）

4.1　箇条書き（itemize）

- データの前処理（欠損値補完・外れ値除去）
- 特徴量エンジニアリング（ワンホットエンコーディング・標準化）
- モデルの学習と交差検証による評価
- ハイパーパラメータチューニング（グリッドサーチ / ベイズ最適化）

4.2　番号付きリスト（enumerate）

1. 研究課題（Research Question）を明確に定義する．

2. 先行研究を体系的にレビューし，知識のギャップを特定する．

3. 仮説を設定し，検証可能な形式にリファインする．

4. データ収集の方法論を設計し，IRB 承認を得る．

5. 統計分析を実施し，結果を可視化する．

4.3 hypo マクロを用いた仮説リスト

- プログラミングスキルと数学スコアには正の相関がある
- 文系学部と理系学部の間には有意なスキル差が存在する
- 自己評価と客観テストの間には系統的な乖離がみられる

5 ソースコードの表示（listings パッケージ）

5.1 Python コード：ピアソン相関係数の実装

```python
import numpy as np

def pearson_correlation(x: np.ndarray, y: np.ndarray) -> float:
    """Calculate Pearson correlation coefficient from scratch."""
    n = len(x)
    mean_x, mean_y = np.mean(x), np.mean(y)
    dx, dy = x - mean_x, y - mean_y

    numerator   = np.sum(dx * dy)
    denominator = np.sqrt(np.sum(dx**2) * np.sum(dy**2))

    if denominator == 0:
        return 0.0
    return numerator / denominator

# --- Usage Example ---
scores_python = np.array([3, 4, 2, 5, 1, 4, 3, 5, 2, 4])
scores_sql    = np.array([2, 3, 1, 5, 1, 4, 2, 4, 3, 3])

r = pearson_correlation(scores_python, scores_sql)
print(f"Pearson r = {r:.4f}")
```

Listing 1: NumPy を用いたピアソン相関係数の計算

6 秘宝 1: TikZ によるニューラルネットワーク描画

TikZ を用いて，入力層・隠れ層・出力層からなる全結合ニューラルネットワークを描画する．深層学習 [3] の基礎であるフィードフォワードネットワークの構造を視覚化した例を示す．

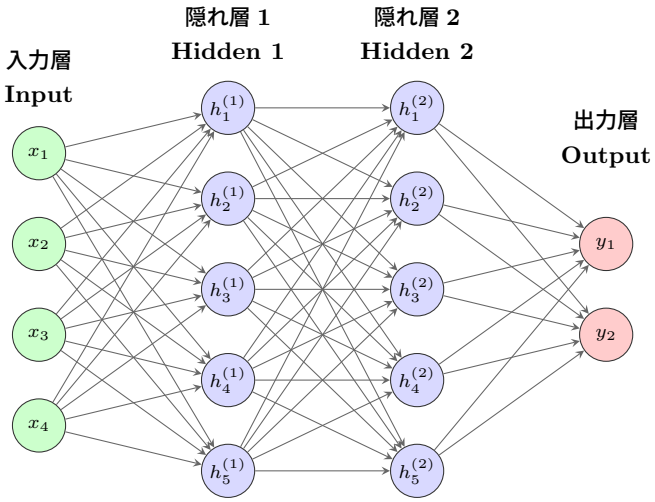

図 6: TikZ で描画した全結合ニューラルネットワーク（4–5–5–2）

図 6 は 4 入力・2 出力のフィードフォワードネットワークを示す．Convolutional Neural Network (CNN) や Recurrent Neural Network (RNN) などのアーキテクチャも TikZ で描画可能である．

7 秘宝 2: Algorithm2e による擬似コード

勾配降下法 [2] の擬似コードを `algorithm2e` パッケージで記述する．

Algorithm 1: Gradient Descent（勾配降下法）

Input: Training data $\{(\boldsymbol{x}_i, y_i)\}_{i=1}^{N}$, learning rate η, max iterations T

Output: Optimized parameters $\boldsymbol{\theta}^*$

Initialize $\boldsymbol{\theta}^{(0)}$ randomly;
for $t = 0$ **to** $T - 1$ **do**
  Compute predictions: $\hat{y}_i = f(\boldsymbol{x}_i; \boldsymbol{\theta}^{(t)}) \quad \forall i$;
  Compute loss: $\mathcal{L} = \frac{1}{N} \sum_{i=1}^{N} \ell(y_i, \hat{y}_i)$;
  Compute gradient: $\boldsymbol{g} = \nabla_{\boldsymbol{\theta}} \mathcal{L}$;
  Update parameters: $\boldsymbol{\theta}^{(t+1)} \leftarrow \boldsymbol{\theta}^{(t)} - \eta\, \boldsymbol{g}$;
  if $\|\boldsymbol{g}\| < \varepsilon$ **then**
    break ;　　`// convergence reached`
return $\boldsymbol{\theta}^{(T)}$;

algorithm 1 に示した更新則は式 (2) と対応する．Adam などの適応学習率法への拡張も同様に記述可能である．

8　秘宝 3: Tcolorbox による装飾枠

学術論文において重要な知見や注意事項を読者に伝えるには，視覚的に目立つ装飾枠が有効である．

Important Insight

Large Language Model (LLM) は開発環境の政治的・文化的バイアスを反映した「確率的ステートマシン」であり，中立的な情報源ではない．同一の問いに対しても，モデルの出身国によって全く異なるナラティブが構築される [4].

Warning

`hyperref` パッケージは必ず `cleveref` よりも**前**に読み込むこと．順序を誤ると参照リンクが正しく生成されない．

Definition

Retrieval-Augmented Generation (RAG) とは，外部知識ベースからの検索結果を Large Language Model (LLM) の入力に付加することで，幻覚（Hallucination）を抑制し事実に基づく回答を生成するフレームワークである [5].

9　秘宝 4: Cleveref による自動ラベル参照

`cleveref` パッケージの `\cref` コマンドは，参照先の種類（図・表・式・アルゴリズム）を自動判定し，日本語ラベルを付加する：

- 数式参照: 式 (1)，式 (2)，式 (3)
- 表参照: 表 1，表 2
- 図参照: 図 1，図 6
- アルゴリズム参照: algorithm 1
- セクション参照: § 1，§ 6
- 複数同時参照: 式 (1) – (3) を比較せよ

10　秘宝 5: 略語自動管理システム

本テンプレートでは，略語が**初回登場時にフルスペル**，2 回目以降は略語のみで自動表示されるカスタムマクロを実装している．

近年の Natural Language Processing (NLP) 分野では, Large Language Model (LLM) が急速に発展している．Generative Adversarial Network (GAN) [6] は画像生成に革命をもたらし，Retrieval-Augmented Generation (RAG) [5] は Large Language Model (LLM) の幻覚問題に対処するために提案された．Reinforcement Learning from Human

Feedback (RLHF) は Large Language Model (LLM) の出力品質を人間のフィードバックに基づいて向上させる手法である．

上記の文では，2 回目に登場した Large Language Model (LLM) や Retrieval-Augmented Generation (RAG) が自動的に略語のみで表示されていることを確認されたい．

略語一覧

略語	正式名称
LLM	Large Language Model
RAG	Retrieval-Augmented Generation
GAN	Generative Adversarial Network
NLP	Natural Language Processing
ML	Machine Learning
CNN	Convolutional Neural Network
RNN	Recurrent Neural Network
SGD	Stochastic Gradient Descent
RLHF	Reinforcement Learning from Human Feedback

11　段組みレイアウト（multicol パッケージ）

左カラム：定量分析

定量分析では数値データに基づく統計的検定を実施する．具体的には，t 検定・χ^2 検定・分散分析（ANOVA）などを用いて群間差の有意性を評価する．サンプルサイズの確保と効果量の報告が不可欠である．

右カラム：定性分析

定性分析ではインタビューやフィールドノートを対象にグラウンデッド・セオリー・アプローチや主題分析（Thematic Analysis）を適用する．コーディングの一貫性を確保するため，複数のコーダーによる信頼性検証が推奨される．

12　便利マクロの使用例

実験結果の要約： 提案手法はベースラインに比べ F1 スコアで +7.3 pp の改善を達成した（表 1）．特に Recall の向上が顕著であり，偽陰性の削減に大きく寄与している．

今後の展望： 本研究ではテキストデータのみを対象としたが，マルチモーダル（画像＋テキスト）への拡張によりさらなる精度向上が見込まれる．Retrieval-Augmented Generation (RAG) [5] の導入も有望なアプローチである．

13　結論

本テンプレートでは，数式（§ 1），図（§ 2），表（§ 3），リスト（§ 4），ソースコード（§ 5），TikZ（§ 6），Algorithm2e（§ 7），Tcolorbox（§ 8），Cleveref（§ 9），Glossaries（§ 10），段組み（§ 11），便利マクロ（§ 12）の 12 カテゴリにわたる組版要素を実演した．

このファイルをコピーし，タイトル・要旨・本文を書き換えるだけで，北米大学院水準の学術論文・レポートを即座に執筆開始できる．

参考文献

[1] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. New York: Springer, 2006. ISBN: 978-0-387-31073-2.

[2] Sebastian Ruder. “An Overview of Gradient Descent Optimization Algorithms”. In: *arXiv preprint arXiv:1609.04747* (2016).

[3] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. “Deep Learning”. In: *Nature* 521.7553 (2015), pp. 436–444. DOI: 10.1038/nature14539.

[4] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. “Attention Is All You Need”. In: *Advances in Neural Information Processing Systems* 30 (2017), pp. 5998–6008.

[5] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 9459–9474.

[6] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. “Generative Adversarial Nets”. In: *Advances in Neural Information Processing Systems* 27 (2014), pp. 2672–2680.